



#mldevelopment ***Water Potability Assessment***



by Anggun Sulis Setyawan


2026

Introduction

Disclaimer

Terinspirasi dari permasalahan akan **krisis air bersih** yang mungkin dihadapi di masa depan akibat kondisi iklim global yang semakin sulit diprediksi, penulis mencoba melihat ini dari sudut pandang perusahaan **penyedia layanan air minum (SPAM)** di Indonesia.

Alur Kegiatan Opeasional



Background Story

Masalah

9/10 ≠ 12%

rumah tangga di Indonesia memiliki akses air minum yang **layak**.
(BPS, 2024)

memiliki akses air minum yang benar-benar aman **sesuai standar kesehatan**.
(Alfathi et al, 2025)

Stimulus





target **peningkatan akses** rumah tangga perkotaan terhadap **air siap minum perpipaan** hingga 51,36%.
(RPJMN, 2025-2029)

Business Case

Peran:

Perusahaan memiliki tanggung jawab untuk **memastikan** bahwa air yang didistribusikan kepada masyarakat telah **memenuhi standar** kualitas, keamanan, dan kesehatan secara konsisten, akurat, dan berkelanjutan.




Tantangan:

Perubahan iklim, limpasan limbah domestik, aktivitas industri, dan degradasi kualitas lingkungan memperbesar **risiko fluktuasi kualitas air**.

Kebutuhan:

Pembangunan **sistem monitoring** kualitas air terintegrasi (sebelum dan setelah pengolahan air).



Target Terdekat:

Perketat proses **assessment kelayakan air** sebelum distribusi ke pelanggan/pengguna.

WATER POTABILITY ASSESSMENT SYSTEM


Objective

- Mengembangkan alat bantu (*tools*) *assessment* potabilitas/kelayakan air berbasis data lab statik yang dimiliki perusahaan.

Scope


- Pengembangan tahap awal, yaitu:
 - membuat model **klasifikasi potabilitas air**,
 - membuat model **deteksi anomali kualitas air**.

System Workflow



Dataset Overview

[water_potability.csv](#)



[\[Lihat Dataset\]](#)

Parameter Air:


- **pH** = tingkat asam-basa air
- **Hardness** = kesadahan oleh garam kalsium dan magnesium
- **Total Dissolved Solids (TDS)** = kemampuan melarutkan mineral dan garam
- **Chloramines** = kadar klorin dalam air
- **Sulfate** = konsentrasi sulfat dalam air
- **Conductivity** = tingkat konduktivitas air
- **Organic Carbon** = kandungan karbon dalam senyawa organik
- **Trihalomethanes** = zat kimia dalam air yang diolah dengan klorin
- **Turbidity** = kekeruhan air

Variabel Target:


- **Potability** = kelayakan air minum (0 = tidak layak, 1 = layak minum)

Kondisi Data:

- **Jumlah data** = 3276 entries
- **Missing Value** = 1434 values
- **Duplikasi** = 0 (Tidak ada)



Data Insight












	count	mean	50%	max
ph	2785.0	7.080795	7.036752	14.000000
Hardness	3276.0	196.369496	196.967627	323.124000
Solids	3276.0	22014.092526	20927.833607	61227.196008
Chloramines	3276.0	7.122277	7.130299	13.127000
Sulfate	2495.0	333.775777	333.073546	481.030642
Conductivity	3276.0	426.205111	421.884968	753.342620
Organic_carbon	3276.0	14.284970	14.218338	28.300000
Trihalomethanes	3114.0	66.396293	66.622485	124.000000
Turbidity	3276.0	3.966786	3.955028	6.739000

Data setiap parameter **terdistribusi normal**, kecuali parameter **Solids** yang sedikit condong ke kiri / *positive skewed* (Mean > Median dan nilai max = 3x Median)


Data Insight

Terdapat **outlier** pada semua parameter. Hal ini dapat dinilai wajar terjadi apabila mempertimbangkan kejadian **fluktuasi kualitas air** akibat berbagai faktor lingkungan.

Informasi outlier akan berguna untuk pengembangan model **deteksi anomali**.




Data Insight



Semua nilai korelasi terhadap *Potability* sangat kecil (mendekati 0).

Artinya, **korelasi linear sangat lemah**. Potabilitas ditentukan melalui kombinasi multi-variabel.


Dengan demikian, **model linear tidak cocok** untuk data ini.




Berdasarkan kelas targetnya, ternyata proporsi dataset diketahui **tidak seimbang (*imbalance*)**.

Untuk mengatasi ini, maka perlu penerapan ***weight balance*** pada proses pelatihan.

Data Preparation



Preprocessing Pipeline



Random Forest Classifier

Gabungan banyak pohon keputusan (*decision tree*) yang akan menentukan hasil klasifikasi berdasarkan suara terbanyak.

Kelebihan

- Akurasi & Stabilitas tinggi
- Mampu menangkap hubungan non-linear
- Tidak sensitif terhadap perbedaan skala fitur
- Relatif tahan terhadap outlier

Kekurangan

- Model cenderung sulit diinterpretasikan secara detail.
- Waktu training dan inferensi lebih lambat dibanding model sederhana.
- Kurang cocok untuk kebutuhan analisis real-time dengan latensi rendah.
- Jika terlalu kompleks, ukuran model besar dan boros memori.

Parameter Model

n_estimators

- Jumlah pohon keputusan (*decision tree*) yang dibangun dalam Random Forest.
- Semakin banyak, prediksi lebih akurat & stabil.
- Jika terlalu banyak, waktu pelatihan & inferensi semakin lama.

max_depth

- Kedalaman (jumlah anak cabang) maksimum setiap pohon keputusan yang dapat mengontrol kompleksitas model.
- Nilai besar, model akan sangat detail. Ada, risiko overfitting.
- Nilai kecil, model terlalu sederhana. Ada risiko underfitting.

min_samples_leaf

- Jumlah minimum data dalam satu daun (*leaf*) pohon.
- Semakin besar, model semakin *smooth* & stabil.
- Dapat mengurangi efek noise dan outlier.

min_samples_split

- Jumlah minimum data yang diperlukan agar suatu node bisa dipecah (*split*).
- Nilai besar, pohon lebih sederhana.
- Nilai kecil, pohon lebih detail.

Evaluasi Performa Model

	precision	recall	f1-score	Label
0	0.62	1.00	0.77	Tidak Layak
1	1.00	0.05	0.10	Layak

Precision: Tingkat ketepatan prediksi positif yang dibuat model.


- Dari semua sampel yang diprediksi tidak layak, 62% memang benar tidak layak.
- Semua sampel yang diprediksi layak memang benar layak.

Recall: Tingkat keberhasilan model dalam mendeteksi seluruh data positif yang sebenarnya.


- Dari semua air yang sebenarnya tidak layak, 100% berhasil terdeteksi.
- Dari semua sampel yang sebenarnya layak, hanya 5% yang berhasil dikenali.

F1-Score:

- Metrik yang menggabungkan *precision* dan *recall*.
- Digunakan ketika ingin keduanya memiliki bobot yang seimbang.



Menetapkan **threshold klasifikasi = 0.69**, sehingga model dapat bekerja lebih ketat dan tidak meloloskan **air tidak layak** dengan mudah. Hal ini dilakukan untuk menjamin **keamanan/kesehatan pengguna**.



Isolation Forest

Algoritma yang dapat mendeteksi data tidak normal dengan cara mengisolasi data tersebut. Data anomali lebih mudah dipisahkan daripada data normal sehingga data yang cepat terisolasi dapat dianggap anomali.

Kelebihan

- Tidak perlu data anomali berlabel
- Skalabel untuk dataset besar
- Relatif tahan terhadap noise
- Tidak bergantung pada distribusi data

Kekurangan

- Perlu *post-analysis* (penjelasan mengapa anomali terjadi)
- Sensitif terhadap parameter *contamination*
- Tidak cocok sebagai classifier, hanya sebagai pelengkap

Parameter Model

n_estimators

- Jumlah *isolation tree* yang dibangun dalam Isolation Forest.
- Semakin banyak, maka skor anomali lebih stabil.
- Jika terlalu sedikit, hasil akan kurang stabil (fluktuatif).
- Jika terlalu banyak, waktu pelatihan & inferensi semakin lama.

max_samples

- Jumlah atau proporsi sampel data yang digunakan untuk membangun setiap pohon (*tree*).
- Nilai besar, pola global lebih terlihat.
- Nilai kecil, fokus ke pola lokal.

contamination

- Perkiraan proporsi data yang dianggap anomali.
- Menentukan *threshold* pemisahan data normal vs anomali.
- Disesuaikan dengan kebutuhan analisis.

max_features

- Jumlah fitur yang dipilih secara acak untuk setiap tree.
- Dapat meningkatkan variasi antar tree.
- Mencegah satu fitur dominan.
- Meningkatkan generalisasi.

Anomali Detection Model


Evaluasi Performa Model

Anomaly Rate = 6,25% ✓


Proporsi/Rate:

- <1% = model terlalu primitif,
- 1-15% = performa sehat/umum,
- >15% = data terlalu noisy/contamination terlalu tinggi, model terlalu sensitif

Distribusi Skor Anomali



- Distribusi melebar → model dapat membedakan data normal vs anomali.



- Dari **400 sampel air tidak layak**, sebanyak **22 sampel** terdeteksi memiliki distribusi data parameter yang tidak wajar.
- Dari **256 sampel air layak**, sebanyak **19 sampel** terdeteksi memiliki distribusi data parameter yang tidak wajar.

Risk Assessment



 **Layak**

Normal



"Air layak konsumsi dan polanya umum."
"Dapat didistribusikan dengan monitoring rutin."

 **Layak**

Anomali



"Air layak konsumsi, namun polanya tidak umum."
"Disarankan untuk melakukan pengecekan lebih lanjut."

 **Tidak Layak**

Normal



"Air tidak layak konsumsi dan pola normal."
"Perlu optimasi proses pengolahan air dan pengecekan lebih lanjut."


 **Tidak Layak**

Anomali



"Air sangat tidak layak konsumsi dan terdeteksi anomali ekstrim."
"Wajib verifikasi laboratorium dan penanganan darurat."

Inference



C
O
B
A
-
APP

Aplikasi Risk Assessment Monitoring Kelayakan Air 💧

Masukkan data setiap parameter kualitas air untuk melakukan Risk Assessment Kelayakan Air**!

Status: Model sudah siap.

Input Data Parameter Kualitas Air

ph

7,00

- +

Hardness

Prediksi Kelayakan Air

Data Input:

	ph	Hardness	Solids	Chloramines	Sulfate	Conductivity	Organic_carbon	Trihalomethanes	T
0	7	200	20000	7	300	400	15	80	

Hasil

Risk Level dan Rekomendasi:

Risk Label: TIDAK LAYAK

Rekomendasi: Air tidak layak konsumsi dan pola normal. Perlu optimasi proses pengolahan air dan pengecekan lebih lanjut.

Conclusion

Water Potability Risk Assessment System berhasil mengimplementasikan pendekatan machine learning dengan kombinasi antara **supervised classification** dan **semi-supervised anomaly detection**. Dan mampu memberikan hasil analisis risk level serta rekomendasi berdasarkan data masukan (*input*) melalui formulir yang dibuat menggunakan streamlit UI.

Catatan:


1

Sistem Risk Assessment yang telah dikembangkan tidak berperan sebagai pengganti uji analisis laboratorium, melainkan sebagai alat bantu (*tools*) untuk mempermudah analisis lanjutan.

2

Input manual pada streamlit UI sering kali berbeda dengan distribusi data pada pelatihan model, sehingga lebih mudah terdeteksi sebagai anomali.

Project Evaluation & Future Improvement



Profil Penulis

Education



- **S1 - Teknik Lingkungan**
2025



2022

Product, Data, & Marketing

- Program studi independen bersama RevoU Tech Academy.



2022

Wirausaha Muda Merdeka

- Program pelatihan kewirausahaan bersama LPiK ITB.



2024

Machine Learning Developer


- Program pelatihan intensif bagi talenta di bidang teknologi yang dirancang Google, dan didukung oleh GoTo serta Traveloka.

Professional



Machine Learning Mentor

Program pelatihan skil digital yang dirancang Dicoding Indonesia dan didukung oleh DBS Foundation.



- External Code Reviewer - Machine Learning Class

Freelancer yang membantu review proyek akhir para siswa di kelas Machine Learning / AI Engineer

Jendela Komunikasi:

✉ angsulwan@gmail.com

[in](#) [Anggun Sulis Setyawan](#)

INTJ

#mldevelopment
Terima Kasih



Full Report



Salam @_bangsuwan

2026